


Sesión 2 · Agente conectado

RAG con documentos, una API real y enrutamiento entre herramientas.

Tu meta de aprendizaje

Conectar el agente a conocimiento privado mediante RAG y a información viva mediante una API, dejando que seleccione la herramienta adecuada.



IDEA CENTRAL

RAG responde con contenido recuperado; una API obtiene o modifica estado externo. No son intercambiables.

1. Reactiva el proyecto

```
python3 -m venv .env
source .env/bin/activate # Windows PowerShell: .env\Scripts\Activate.ps1
pip install -r requirements.txt
cp .env.example .env
az login
```


Copia FOUNDRY_PROJECT_ENDPOINT y FOUNDRY_MODEL_NAME en .env. Trabaja desde la carpeta que contiene el archivo de conocimiento.

2. Diseña el documento de prueba

Usa datos que el modelo no pueda adivinar. Por ejemplo: días base, regla por antigüedad, plazo de solicitud y límite de acumulación. Incluye título, secciones y lenguaje explícito.

```
POLÍTICA DE VACACIONES – ACME SPA
- 15 días hábiles base.
- Desde el quinto año: +3 días.
- Solicitud: mínimo 20 días de anticipación.
- Máximo acumulable: 10 días del año anterior.
```

3. Comprende el flujo RAG



- Indexar no es “entrenar” el modelo.
- La calidad depende de documento, chunking, consulta y recuperación.
- La respuesta debe reconocer cuándo la evidencia no alcanza.

4. Sube, indexa y conecta File Search

```
from azure.ai.projects.models import PromptAgentDefinition, FileSearchTool

openai = project.get_openai_client()
vector_store = openai.vector_stores.create(name="vs-politicas")
with open("politica-vacaciones.txt", "rb") as archivo:
    openai.vector_stores.files.upload_and_poll(
        vector_store_id=vector_store.id, file=archivo
    )
file_search = FileSearchTool(vector_store_ids=[vector_store.id])
agent = project.agents.create_version(
    agent_name="agente-rrhh",
    definition=PromptAgentDefinition(
        model=os.environ["FOUNDRY_MODEL_NAME"],
        instructions="Usa el documento; si no hay evidencia, dilo.",
        tools=[file_search],
    ),
)
```

SDK ACTUALIZADO

Ejemplo migrado a azure-ai-projects 2.4.0: vector stores mediante OpenAI client, agente versionado y herramientas desde azure.ai.projects.models.

5. Prueba la recuperación

1

Pregunta exacta

“¿Cuántos días tengo con 6 años?” Respuesta esperada: 18.

2

Pregunta combinada

Pide días y plazo de solicitud; debe unir dos fragmentos.

3

Dato ausente

Pregunta por bonos. Debe indicar que el documento no lo contiene.

4

Trazabilidad

Registra consulta, respuesta esperada, respuesta real y evidencia encontrada.

6. Conecta una API real

La función realiza dos llamadas: ciudad → coordenadas y coordenadas → clima. Usa timeout, valida respuestas y transforma el JSON en una salida pequeña.

```
def obtener_clima_real(ciudad: str) -> str:
    geo = requests.get(
        "https://geocoding-api.open-meteo.com/v1/search",
        params={"name": ciudad, "count": 1, "language": "es"},
        timeout=10,
    )
    geo.raise_for_status()
    datos = geo.json()
    if not datos.get("results"):
        return f"No encontré la ciudad '{ciudad}'."
    lugar = datos["results"][0]
    clima = requests.get(
        "https://api.open-meteo.com/v1/forecast",
        params={
            "latitude": lugar["latitude"],
            "longitude": lugar["longitude"],
            "current": "temperature_2m,wind_speed_10m",
        },
        timeout=10,
    )
    clima.raise_for_status()
    actual = clima.json()["current"]
    return f"{lugar['name']}: {actual['temperature_2m']} °C"
```

7. Combina las dos herramientas

```
agent = project.agents.create_version(
    agent_name="agente-todoterreno",
    definition=PromptAgentDefinition(
        model=os.environ["FOUNDRY_MODEL_NAME"],
        instructions=("Políticas: File Search. Clima: función. "
                     "No inventes y explica límites."),
        tools=[file_search, clima_tool],
    ),
)
# Procesa cada function_call y devuelve FunctionCallOutput.
```

"Vacaciones"	→	File Search	→	Documento
"Clima actual"	→	Function tool	→	Open-Meteo

8. Evalúa como ingeniero

Caso	Se espera	Falla a detectar
RAG conocido	Respuesta respaldada	Dato inventado
RAG ausente	Declara ausencia	Confianza falsa
API normal	Dato actual	Sin timeout
API inválida	Mensaje controlado	Traceback
Pregunta mixta	Usa ambas	Omite una herramienta

9. Seguridad, costos y limpieza

- Claves de APIs en variables de entorno o un gestor de secretos.
- Limita tamaño, tipo y procedencia de archivos.
- Agrega expiración a vector stores temporales y elimina recursos de prueba.
- No permitas acciones sensibles sin validación y confirmación humana.

MINI RETO

Sustituye la política por un documento propio, conecta otra API, redacta el enrutamiento y documenta seis pruebas y dos fallos encontrados.